

2026Summer

育种模型项目:

README & AI Coding 指南

给 coworker 的项目速查手册。

上半部分是项目 README，下半部分是使用 AI (Claw/GPT/Claude) 编码时必须告知 AI 的上下文。

项目 README

1 项目名称

环境-作物-管理互作模型 (Environment-Crop-Management Interaction Model)

对标: Xiao et al. (2024, *Nature Food* 5:59-71)

2 目标

利用公开数据构建"环境指纹 + 品种性状 + 管理方案"三要素模型，产出两套结果:

1. 最优农艺管理推荐 (氮肥、灌溉、秸秆还田)

2. 最优育种改良方向 (哪些性状值得改良、改良幅度与产量增益的关系)

3 技术架构 (5 层数据流)

第一层：数据获取层。负责从公开数据源下载原始栅格/表格数据，存放于 2026-SP/Data 目录下。涉及 Python 的 rasterio、urllib、BeautifulSoup 等库和手动浏览器下载。

第二层：特征工程层。将不同分辨率、不同投影的多源数据统一到 1km 网格，构建标准化的环境指纹矩阵。核心工具为 `rasterio`（重采样）、`geopandas`（空间连接）、`pandas`（表格操作）。

第三层：建模层。使用 XGBoost 回归器训练从环境指纹到产量/环境指标的映射模型。核心工具为 `xgboost`、`scikit-learn`（交叉验证、超参数调优）。

第四层：优化层。将训练好的 XGBoost 模型作为代理模型（surrogate），使用 NSGA-II 多目标遗传算法搜索最优的管理方案组合。核心工具为 `pymoo`。

第五层：解释与部署层。使用 SHAP 解释特征重要性，使用 Bootstrap 量化不确定性，使用 FastAPI 将模型部署为 RESTful 服务。

4 仓库结构

2026-SP/

```
|— .github/workflows/ # CI/CD
|— data/             # 数据目录 (gitignore, 不上传大文件)
|— src/
|   |— data_ingest/  # 数据获取
|   |— features/     # 特征工程
|   |— models/       # 建模与训练
|   |— optimization/ # NSGA-II 优化
|   |— visualization/ # 可视化
|— tests/            # 单元测试
|— docs/             # 文档
|— notebooks/        # Jupyter 探索
|— requirements.txt
|— Dockerfile
|— README.md
|— .gitignore
```

5 环境搭建

方案一：Conda (推荐)

方案二：venv

```
conda create -n 2026sp python=3.11
```

```
conda activate 2026sp
```

```
pip install numpy pandas xarray rasterio geopandas xgboost shap scikit-learn pymoo optuna
matplotlib seaborn jupyter fastapi uvicorn
```

```
python -m venv venv
venv\Scripts\activate # Windows
pip install -r requirements.txt
```

6 分支策略 (GitHub Flow)

- `main`: 永远可运行，只通过 PR 合并，禁止直接 push
- `feature/xxx`: 从 main 创建，一个分支只做一件事 (如 `feature/add-nsga2-optimizer`)
- `fix/xxx`: 紧急修复 (如 `fix/memory-leak-in-rasterio`)

7 提交信息规范 (Conventional Commits)

前缀	含义	示例
feat	新功能	feat: 添加 SHAP 特征重要性分析模块
fix	修复 bug	fix: 修复 rasterio 内存泄漏问题
docs	文档更新	docs: 更新 API 接口文档
refactor	代码重构	refactor: 将数据加载逻辑提取为独立模块
test	测试相关	test: 添加 XGBoost 交叉验证单元测试
chore	杂项/构建	chore: 更新 requirements.txt 依赖版本

8 预期分工

角色	负责模块	核心技能	交付物
数据工程师	第 1-2 层：数据获取、预处理、特征工程	rasterio, geopandas, pandas, xarray	环境指纹矩阵 (CSV/Parquet)
建模工程师	第 3-4 层：XGBoost	xgboost, scikit-learn,	训练好的模型(pkl)、

	训练、NSGA-II 优化	pymoo, optuna	优化结果 CSV
分析工程师	第 5 层：SHAP 解释、Bootstrap、统计分析	shap, numpy, scipy, R/tidyverse	特征重要性图、不确定性区间、统计检验报告
部署工程师	第 5 层：API 服务、可视化、文档	FastAPI, Docker, GitHub Actions	Docker 镜像、API 文档、使用手册

AI Coding 指南

使用 AI (Claw/GPT/Claude/Copilot) 写代码前，请把以下内容粘贴给 AI，作为项目上下文！

1 项目概况 (告诉 AI 这是干什么的)

本项目是一个农业模型研究项目，目标是用 XGBoost 模拟作物过程模型 (APSIM) 的输出，然后用 NSGA-II 多目标遗传算法搜索最优管理方案。
研究区域: 北京市平谷区
作物: 冬小麦 + 夏玉米轮作
对标论文: Xiao et al. (2024, Nature Food 5:59-71)
项目代码仓库路径: D:\2026-SP\
数据目录: D:\2026-SP\Data\

2 固定参数 (必须硬编码或配置化)

以下参数是整个项目的"物理常数"，任何代码都应使用这些值，AI 不能随意改动:

+空间参数
+时间参数

+特征维度 (总计约 55-75 维)
+模型目标变量
+XGBoost 默认超参 (可通过 Optuna 调优)
+NSGA-II 默认参数
+Bootstrap 不确定性量化

```
target_crs: "EPSG:4326"      # 统一坐标系 WGS84
resolution: 0.008333        # 约 1km (度)
grid_points: 65             # 平谷区 1km 网格点数
study_area: "北京市平谷区"

growing_season: [3, 4, 5, 6, 7, 8, 9] # 生长季月份
base_temperatures: [0, 5, 10, 15, 20, 25] # GDD 基温阈值

n_bio_vars: 19              # WorldClim 生物气候变量
n_monthly_clim: 14          # 3-9 月月均温 + 月降水
n_terrain: 3                # 海拔、坡度、坡向
n_soil: 8                   # 砂粒、粉粒、黏粒、SOC、pH、BD、CEC、N
n_co2: 1                    # 大气 CO2 浓度
n_variety: 8                # 品种性状 (来自品种审定公告)

targets:
- wheat_yield               # 小麦产量
- maize_yield               # 玉米产量
- n_leaching                # 氮淋溶量
- delta_soc                 # 土壤有机碳变化

xgb_defaults:
n_estimators: 500
max_depth: 6
learning_rate: 0.05
subsample: 0.8
colsample_bytree: 0.8
random_state: 42
```

```
nsga2_defaults:
  pop_size: 200
  n_gen: 500
  decision_vars:          # 管理方案决策变量及其范围
    nitrogen_rate: [0, 300]  # kg/ha
    irrigation_amount: [0, 400] # mm
    straw_return_rate: [0, 1]  # 0-1 比例

bootstrap:
  n_iterations: 1000
  ci_level: 0.95          # 95% 置信区间
```

3 命名与格式规范 (AI 必须遵守)

所有代码严格遵循以下规范，违反即为错误:

1. 变量/函数/文件名: snake_case (如 extract_features, build_matrix.py)
2. 列名: 英文小写 + 下划线 (如 bio_1, gdd_10, sand_pct)
3. 缺失值: NaN (决不允许用 -999, -9999 等魔法数字)
4. 类名: PascalCase (如 EnvironmentalFingerprintBuilder)
5. 常量: UPPER_SNAKE_CASE (如 TARGET_CRS, GRID_RESOLUTION)
6. 文件头: 必须包含模块 docstring
7. 可执行代码: 必须放在 if __name__ == "__main__" 中
8. 可配置参数: 抽取到 config.yaml, 禁止硬编码在 Python 中
9. 随机种子: 全局固定为 42 (np.random.seed(42), random_state=42)

4 模块间接口规范 (数据格式约定)

所有模块间传递的数据遵循以下约定:

格式: CSV 或 Parquet

行定义: 每一行 = 一个地理位置点 (网格)

列命名: snake_case (如 gdd_10, slope_deg)

缺失值: NaN (不是 -999!)

空间参考: WGS84 (EPSG:4326)

分辨率: 0.008333 度 (约 1km)

坐标列: lon, lat (必须保留)

示例一行数据:

lon,lat,year,bio_1,bio_2,...,gdd_10,...,sand_pct,...,wheat_yield
116.9,40.1,2020,12.5,3.2,...,1850.3,...,42.1,...,6.8

5 关键代码模式 (给 AI 的模板)

特征工程模块模板:

```
"""
特征工程模块: 从原始栅格数据构建环境指纹矩阵

输入: Data/WorldClim/*.tif, Data/SRTM/*.tif, Data/SoilGrids/*.tif
输出: features_matrix.parquet
用法: python -m src.features.build_matrix --config config.yaml
"""

import rasterio
import numpy as np
import pandas as pd
from pathlib import Path

class EnvironmentalFingerprintBuilder:
    """环境指纹构建器"""

    def __init__(self, config):
        self.data_dir = Path(config["data_dir"])
        self.grid_points = pd.read_parquet(config["grid_file"])
        self.target_crs = "EPSG:4326"

    def extract_worldclim_bio(self):
        """提取 19 个生物气候变量"""
        pass

    def extract_all(self):
        """执行完整提取流水线"""
```

```
pass
```

```
if __name__ == "__main__":  
    main()
```

模型训练必须使用空间分块交叉验证:

由于空间自相关 (相邻网格环境相似), 简单随机划分会导致过拟合。

必须使用 Spatial Block CV:

- 将 65 个网格按地理位置分为 5 块
- 每次用 4 块训练, 1 块验证
- 旋转 5 次

AI 写模型代码时必须使用此策略, 不能用 `train_test_split` 简单随机划分。

6 可视化规范

所有图表遵循:

- 字体: Times New Roman
- 配色: 色盲友好调色板 (viridis / cividis / ggsci::scale_color_npg)
- 字号: $\geq 8\text{pt}$
- 子图标签: (a)(b)(c) 格式 (不是 1,2,3)
- 导出格式: PDF 或 600 DPI TIFF (不是 PNG/JPG)

7 常见坑点 (AI 必须知道的)

1. rasterio 在 Windows 上必须用 conda 安装, 不能用 pip
(conda install -c conda-forge rasterio)
2. 训练前必须检查 NaN:
`df.isnull().sum()` 和 `np.isinf(X).sum()`
3. 大文件 (>100MB) 不上传 Git, 使用 .gitignore 排除
4. SHAP 与某些 matplotlib 版本不兼容:
使用 `shap >= 0.42 + matplotlib >= 3.7`
5. R ggplot2 中文显示问题:
安装 showtext 包 + `font_add()` 注册中文字体
6. 数据单位间留空格: "180 kg/ha" 不是 "180kg/ha"
7. 缩写首次出现给出全称:

"Growing Degree Days (GDD)"

8. SoilGrids 数据获取需要使用 vsicurl + COG VRT 方式,
不是直接下载整个文件