

北京市平谷区冬小麦-夏玉米轮作体系

环境指纹×机器学习育种模型

前期研究纲要 — 供导师审阅与 coworker 入组参考

彭宇程 2026 年 7 月 28 日

一、项目概述

本项目构建了一套机器学习框架，将环境指纹（涵盖气候、土壤、地形的全维度栅格变量）与多品种作物性状和管理情景相结合，实现产量预测与农艺措施优化。研究区域为北京市平谷区（234 个 1 km 网格），作物体系为冬小麦-夏玉米一年两熟轮作。

核心创新在于从传统单点或单因子分析迈向空间显式、多维度的研究范式：环境指纹捕获每个网格的全谱生物物理条件，机器学习模型（XGBoost、随机森林、分位数随机森林）解析复杂的基因型×环境×管理（G×E×M）互作效应。模型解释借助 SHAP 值（Shapley 加法解释）配合 Bootstrap 置信区间，同时提供机制洞察与不确定性量化。

二、研究背景与知识缺口

作物产量预测长期依赖过程模型（如 APSIM、DSSAT），这些模型参数化工作量大，且区域外推能力有限。机器学习提供了新路径：数据驱动的模式无需显式的生理方程即可捕获非线性 G×E×M 关系。但当前研究存在三个关键缺口：

- 环境表征不足：多数 ML 产量研究仅使用少数气候变量（如生长季均值温度、降水），丢失了极端事件、季节性信息和土壤约束信号。
- 不确定性量化缺失：文献以点预测为主，鲜有报道预测区间与空间不确定性分布图。
- 环境约束下的管理优化空白：现有优化研究（如 Xiao et al. 2024, Nature Food）使用区域聚合数据，尚未探索网格级、耦合环境指纹的多目标优化。

本研究同时针对以上三个缺口展开。

三、研究区域与轮作体系

参数	内容
研究区域	北京市平谷区（117.1° E, 40.1° N）
网格分辨率	1 km × 1 km，共 234 个网格
轮作体系	冬小麦（10 月-次年 6 月）-夏玉米（6 月-10 月）一年两熟
气候特征	暖温带季风气候；年均温 11-12° C；年降水 600-650 mm
冬小麦品种	8 个品种（京冬 8 号/12 号/17 号/22 号，中麦 175/1062，轮选 987/169）
夏玉米品种	8 个品种（文献和审定公告已提取）
管理数据	自主设计 14 情景 + Xiao et al. (2024) 公开数据集（CC BY 4.0）

四、数据清单

4.1 环境指纹矩阵

核心数据为 234×73 矩阵（Outputs/pinggu_environmental_data.csv），每行代表 1 个 1 km 网格，每列代表 1 个环境变量。数据缺失率 0.3%（仅地形衍生变量 3 列边缘网格），可建模变量 71/73（97%）。

类别	数据源	变量数	分辨率	状态
生物气候变量	WorldClim 2.1	19 (biol-bio19)	2.5 arc-min	已就绪
逐月平均温度	WorldClim 2.1	12 (tavg 01-12)	2.5 arc-min	已就绪
逐月降水量	WorldClim 2.1	12 (prec 01-12)	2.5 arc-min	已就绪
土壤属性	SoilGrids 2.0 (ISRIC)	8 (砂/粉/黏/有机碳/全氮/pH/容重/阳离子交换量, 0-5cm)	250 m→5 km	已就绪
地形	SRTM 90m (CGIAR-CSI)	3 (海拔、坡度、坡向)	90 m	已就绪
生长期日	派生计算	6 (GDD0/5/10/15/20/25)	1 km	从 tavg 重新生成
土壤水分常数	派生计算	3 (SAT、DUL、LL15)	1 km	从 SoilGrids 重新生成
品种性状	文献+审定公告提取	8 小麦×8 性状；8 玉米×9 性状	品种级	已就绪
管理情景（自主）	自主设计	14 情景 (N×灌溉×密度)	网格级	已就绪
管理数据（外部）	Xiao et al. (2024) Figshare	4 文件 (施氮、灌溉、产量；基准期+SSP 情景)	1 km	已就绪 (CC BY 4.0)

4.2 管理数据：互补双来源

来源一（自主设计）：14 个管理情景，组合施氮量（0/150/300 kg ha⁻¹）、灌水量（0/200/400 mm）和播期密度变化，通过 management_grid_default.csv 应用于全部 234 网格。设计参考 Chen et al. (2014) Nature 及 Bai et al. (2024) Nature Food 5:148-159。

来源二（公开数据）：Xiao et al. (2024) "Spatiotemporal co-optimization of agricultural management practices" (Nature Food 5:59-71)。数据集从 Figshare 下载（DOI: 10.6084/m9.figshare.24471919.v5, CC BY 4.0 许可）。包含小麦和玉米的优化施氮量、灌溉量和产量图，覆盖三个时段（基准期、2030s、2060s），分 SSP2-4.5 和 SSP5-8.5 两种情景。已下载 4 个关键文件（共 61 MB）；主数据文件 Allregions.rds（57.3 MB）需用 R 语言转 CSV。

五、分析方法管线

5.1 特征工程（R1 阶段 + S1 审计）

73 变量环境指纹矩阵将按五步流程进行系统特征工程：（1）数据清洗（异常值处理、缺失值填补）；（2）特征构建（交互项、植被指数等）；（3）维度评估（PCA、方差膨胀因子）；（4）特征筛选（Boruta、基于 SHAP 的递归特征消除）；（5）敏感性分析（单变量扰动）。

特征审计员 S1 使用替代方法（如互信息法对照 Boruta）独立验证 R1 输出，发现差异提交讨论后再进入建模阶段。

5.2 建模（R2 阶段 + S2 审计）

建模管线遵循渐进复杂度策略：

步骤	方法	目的	预期产出
1 基线	多元线性回归	建立性能下限	R ² 、RMSE 基线值
2 集成树	随机森林 (Breiman 2001)	稳健非线性基线	特征重要性排序
3 梯度提升	XGBoost (Chen & Guestrin 2016)	结构化数据最优模型	Optuna 优化后的最佳参数
4 超参调优	Optuna (Akiba et al. 2019)	贝叶斯优化 XGBoost 参数	最优试验+参数空间分布图

5 不确定性	分位数随机森林 (Meinshausen 2006)	每网格 90%预测区间	空间不确定性分布图
6 多目标优化	NSGA-II	产量-施氮量 Pareto 前沿	最优管理组合方案

模型验证采用空间交叉验证（分块 k-fold, k=5-10），防止空间自相关虚增性能评估。审计员 S2 通过置换检验、残差空间自相关分析（Moran's I）和超参扰动敏感性检验独立验证模型稳健性。

5.3 模型解释（R3 阶段）

SHAP 值（Lundberg & Lee 2017）将每个预测分解为各特征的加性贡献。核心分析包括：（1）全局特征重要性排序及 Bootstrap 95%置信区间；（2）前 8-10 位特征的 SHAP 依赖图；（3）SHAP 交互值检测非加性 G×E 效应；（4）SHAP 值空间映射，识别各环境因子在何处主导产量限制；（5）构建环境效应相似性指数（EESI），为品种布局推荐提供依据。

5.4 因果推断（可选扩展）

若时间允许，将 PCMRI 算法（Runge et al. 2019）应用于环境指纹时间序列，区分直接因果驱动与间接相关关系，增强 SHAP 结果的机制解释力。

六、创新点

优先级	创新点	新颖性	可行性
P0 必做	动态环境指纹：73 变量全维度网格化表征替代传统少数气候变量	华北平原 1 km 分辨率全谱环境指纹的首次应用	数据已编译完成
P0 必做	空间 CV+不确定性：分块 k-fold 交叉验证+QRF 预测区间	针对性解决农业 ML 中普遍的空间自相关虚增问题，提供逐网格置信度	scikit-learn 已有现成工具
P1 强推	SHAP 交互值 G×E×M 分解+Bootstrap 置信区间	将 SHAP 从点估计推向统计推断，结果农学家可直接解读	Python shap 库/R shapr 包支持
P1 强推	环境效应相似性指数（EESI）：品种推荐分区	将黑箱模型输出转化为可操作的农艺决策	概念可行，待实现
P2 可选	PCMRI 因果结构学习	量化环境因子的直接 vs 间接效应，农业 ML 中罕见	算法已公开，取决于时间
P2 可选	NSGA-II 多目标优化	网格级管理方案组合，平衡产量与氮投入	pymoo/deap 库支持

七、团队架构与 workflow

项目采用双轨验证架构（3R+5S，v4 定稿）。三条主线角色（R1-R3）执行核心管线；两条审计角色（S1-S2）独立验证各阶段；一项写作角色（S4）贯穿始终；两项可视化角色（S5-S6）负责全部图表。每个主线产出均经审计交叉验证后方可进入下一阶段。

代号	角色	职责	核心交付物
R1	特征工程架构师	数据清洗→特征构建→降维→筛选	最终特征矩阵（234×k）
S1	特征审计员	使用替代方法独立验证 R1 输出	审计报告+核准特征集
R2	建模与优化工程师	基线模型→集成→XGBoost→QRF→NSGA-II	训练模型+预测结果+Pareto 前沿
S2	模型验证员	空间 CV+置换检验+Moran's I 审计	验证报告+核准模型
R3	SHAP 解释工程师	SHAP 分析+Bootstrap 置信区间+EESI 构建	SHAP 分析包+解读报告
S4	论文撰写	全程同步撰写（持续产出）	论文初稿（目标期刊：JIA）
S5	主体图设计师	Fig 1-7 全流程制作（600 DPI TIFF）	7 张正文图表
S6	附录图设计师+规范管理	Fig S1-S12 制作（300 DPI PNG）；维护风格表	12 张附图+matplotlib 风格文件

预计工期：17 个工作日（约 3.5 个自然周），含迭代与导师审阅缓冲。

7.1 数据流

源数据位于 Data/目录（WorldClim、SoilGrids、SRTM、Variety、Management）。特征工程脚本在 src/r1_feature_engineering/中运行，读取 Data/数据并将中间产出写入 Outputs/intermediate/。建模脚本在 src/r2_modeling/中读取特征矩阵，训练模型并保存.pkl 文件至 Outputs/models/。解释脚本在 src/r3_shap_interpretation/中加载模型并输出 SHAP 结果。全项目图表统一使用 config/style_2026sp.mplstyle 风格文件，主体图输出至 Outputs/figures/main/（S5），附录图输出至 Outputs/figures/supp/（S6）。

八、预期成果

8.1 学术产出

- 一篇同行评审论文，目标期刊 Journal of Integrative Agriculture (JIA, IF 约 4.0)，备选 Agronomy-Basel 或 PeerJ。
- 一个经过验证的、可解释的网格化产量预测与管理优化 ML 框架，可推广至其他区域。
- 开源代码库 (GitHub: github.com/DearDragon233/2026-SP)，按角色模块组织全部分析脚本。

8.2 图表产出 (共 19 张)

编号	内容	类型	制作
Fig 1	研究区域总览+环境指纹设计示意图	总览	S5
Fig 2	特征重要性排序+Bootstrap 95%置信区间	方法/结果	S5
Fig 3	模型性能对比 (5 种模型, 空间 CV)	结果	S5
Fig 4	空间产量预测图+QRF 不确定性分布	结果	S5
Fig 5	SHAP 摘要+前 8 位特征依赖图	结果	S5
Fig 6	SHAP 交互热力图+G×E 效应分解	结果	S5
Fig 7	NSGA-II Pareto 前沿+优化管理方案组合	结果	S5
Fig S1-S12	数据诊断、敏感性分析、补充地图等	附录	S6

8.3 数据产品

- 清洗后的环境指纹矩阵 (234 网格×k 特征)，发表时附带 DOI 公开存档。
- 从 Xiao et al. (2024) 提取的管理数据 CSV 格式 (便利 Python 用户，保留原始.rds 文件)。
- 训练模型 checkpoint 文件 (.pk1)，确保结果可复现。

九、核心参考文献

全文精读指南（34 篇文献，含详细阅读笔记）见 ManageFiles/26SP_参考文献精读与使用指南.pdf。10 篇 OA 论文 PDF 已下载至 Paper/文件夹。核心方法学文献如下：

陈天奇, Guestrin C. 2016. XGBoost: 可扩展的树提升系统. KDD 2016. arXiv:1603.02754.

Lundberg SM, Lee SI. 2017. 模型预测的统一解释方法. NeurIPS 2017. arXiv:1705.07874.

Breiman L. 2001. 随机森林. Machine Learning 45(1):5-32.

Meinshausen N. 2006. 分位数回归森林. Journal of Machine Learning Research 7:983-999.

Shahhosseini M 等. 2021. 机器学习与作物模型耦合. Agricultural and Forest Meteorology 307:108486.

Xiao L 等. 2024. 农业管理措施的时空协同优化. Nature Food 5:59-71. [数据: Figshare, CC BY 4.0]

Bai S 等. 2024. 作物产量预测的环境指纹方法. Nature Food 5:148-159.

Runge J 等. 2019. 大规模时间序列因果关联的检测与量化. Science Advances 5:eaau4996.

Akiba T 等. 2019. Optuna: 新一代超参数优化框架. KDD 2019. arXiv:1907.10902.

何中虎等. 2010. 中麦 175 高产高效广适特性解析. 中国农业科学 43(3):459-467.

十、当前状态与下一步

事项	状态
环境指纹 CSV (234×73)	已就绪
品种性状数据 (8 小麦+8 玉米)	已就绪
管理情景 (14 自主+Xiao 2024 公开数据)	已就绪
参考文献 PDF (10 篇 OA 论文, 17 MB)	已就绪

项目管理文档（9 PDF+2 MD）	已就绪
GitHub 仓库结构（src/模块化+Outputs/子文件夹）	已就绪
R1：特征工程	待启动
S1：特征审计（与 R1 并行）	待启动
R2：建模管线	待启动
S5/S6：图表制作	待启动（可提前）